

MPECI 2025-2026

Disponibilidade de Sistemas e de Servidores

Noção de disponibilidade

- A disponibilidade de um elemento é a probabilidade de o elemento estar operacional em qualquer instante de tempo.
- Para um dado elemento i , seja:
 - $MTBF_i$ (*Mean Time Between Failures*): tempo médio entre falhas do elemento i
 - $MTTR_i$ (*Mean Time To Repair*): tempo médio de reparação do elemento i
- então, a disponibilidade a_i do elemento i é dada por:

$$a_i = \frac{MTBF_i}{MTBF_i + MTTR_i}$$

- Exemplos:
 - se uma ligação falha em média ao fim de 1 ano ($MTBF = 365.25 \times 24 = 8766$ horas) e demora em média 2 dias a ser reparada e voltar a estar operacional ($MTTR = 2 \times 24 = 48$ horas), então a sua disponibilidade é 0.99455 (= 99.455%)
 - se um router falha em média ao fim de 90 dias ($MTBF = 90 \times 24 = 2160$ horas) e demora em média 3 horas a ser reparado (ou substituído) e reconfigurado para ficar operacional ($MTTR = 3$ horas), então a sua disponibilidade é 0.99862 (= 99.862%)

Noção de disponibilidade


- A medição da disponibilidade de um elemento é definida para um determinado intervalo de tempo

Disponibilidade	<i>Downtime</i> por ano	<i>Downtime</i> por mês
90% (um nove)	36.53 dias	73.05 horas
99% (dois naves)	3.65 dias	7.31 horas
99.9% (três naves)	8.77 horas	43.83 minutos
99.99% (quarto naves)	52.6 minutos	4.38 minutos
99.999% (cinco naves)	5.26 minutos	26.3 segundos
99.9999% (seis naves)	31.56 segundos	2.63 segundos


Downtime: tempo total em que o elemento não está disponível (i.e., que está indisponível)

Disponibilidade de um sistema composto por múltiplos elementos


- Quando um sistema é composto por múltiplos elementos cujas disponibilidades são independentes entre elementos, a disponibilidade do sistema é calculada modelando o sistema como um grafo direcionado de elementos em série ou em paralelo.
- As regras para decidir se os elementos devem ser colocados em série ou em paralelo são:
 - Um conjunto de elementos é colocado em série se o sistema falha quando um elemento falha (a ordem não tem nenhum significado):



- Um conjunto de elementos é colocado em paralelo se o sistema falha apenas quando todos os elementos falham simultaneamente:



Disponibilidade de um sistema com os elementos em série




- A disponibilidade A do sistema é a probabilidade de todos os elementos estarem disponíveis (i.e., a funcionar).
- Sabendo a disponibilidade a_i de cada elemento i (e se as disponibilidades entre os diferentes elementos forem estatisticamente independentes), a disponibilidade do sistema é dada pelo produto das disponibilidades de todos os elementos:

$$A = a_1 \times a_2 \times \cdots \times a_n$$

- Propriedade:
 - A disponibilidade do sistema é menor (i.e., pior) ou igual do que a disponibilidade do elemento menos disponível
- Exemplo:
 - Um sistema com 3 elementos em série (com disponibilidade de 99.9% cada) tem uma disponibilidade de 99.7%

Disponibilidade de um sistema com os elementos em paralelo




- A disponibilidade A do sistema é a probabilidade de pelo menos um elemento estar disponível (i.e., a funcionar).
- Sabendo a disponibilidade a_i de cada elemento i (e se as disponibilidades entre diferentes elementos forem estatisticamente independentes), a disponibilidade do sistema é dada por $1 -$ (a probabilidade de todos os elementos estarem indisponíveis):

$$A = 1 - [(1 - a_1) \times (1 - a_2) \times \cdots \times (1 - a_n)]$$

- Propriedade:
 - A disponibilidade do sistema é maior (i.e., melhor) ou igual do que a disponibilidade do elemento mais disponível
- Exemplo:
 - Um sistema com 3 elementos em paralelo (com disponibilidade de 99.0% cada) tem uma disponibilidade de 99.9999% (seis noves)

Disponibilidade de um sistema composto por múltiplos elementos

Se o sistema não for apenas um conjunto de elementos em série ou em paralelo, reduz-se iterativamente o grafo num outro com menos elementos substituindo um conjunto de elementos (em série ou em paralelo) por um elemento único com a disponibilidade equivalente.






$$A_{12} = 1 - (1 - a_1) \times (1 - a_2)$$

$$A_{124} = A_{12} \times a_4$$

$$A_{35} = a_4 \times a_5$$


$$A = 1 - (1 - A_{124}) \times (1 - A_{35})$$



Disponibilidade de um sistema composto por múltiplos elementos

No caso geral, a redução iterativa anteriormente descrita pode não ser suficiente para determinar a disponibilidade do sistema.

Neste caso, temos de usar uma técnica de *factoring* de um elemento para decompor o sistema em 2 sistemas mais simples.





- Considere-se um sistema cuja disponibilidade A queremos determinar.
- Considere-se um elemento i do sistema cuja disponibilidade é a_i .
- Se designarmos por A_i^{up} a disponibilidade do sistema quando o elemento i está disponível e A_i^{down} a disponibilidade do sistema quando o elemento i não está disponível, então:

$$A = a_i \times A_i^{up} + (1 - a_i) \times A_i^{down}$$

Disponibilidade de um sistema composto por múltiplos elementos

Aplicando o factoring ao elemento 2 deste exemplo:




Disponibilidade do sistema quando o elemento 2 está DOWN:

$$A_2^{down} = 1 - (1 - a_1 \times a_4) \times (1 - a_3 \times a_5)$$

Disponibilidade do sistema:

$$A = a_2 \times A_2^{up} + (1 - a_2) \times A_2^{down}$$




Disponibilidade do sistema quando o elemento 2 está UP:

$$A_2^{up} = 1 - (1 - a_4) \times (1 - a_5)$$


Disponibilidade de um sistema composto por múltiplos elementos

Consederemos os dois sistemas (usados anteriormente) em que todos os elementos têm disponibilidade 0.99 (dois noves)

Sistema A



Sistema B



Calculando a disponibilidade seguindo os métodos anteriores:

- disponibilidade do sistema A é 0.999799
- disponibilidade do sistema B é 0.999897

O sistema B tem maior disponibilidade porque permite mais combinações de falhas de elementos sem que o sistema falhe:

- se os elementos 3 e 4 falharem, o sistema A falha enquanto que o sistema B não falha

Disponibilidade de um servidor (i)

Servidor analisado como um único elemento


Considerando que:

- a taxa de falhas do servidor por unidade de tempo é λ (i.e., o servidor falha em média ao fim $1/\lambda$ unidades de tempo)
 - a taxa de reparações por unidade de tempo do servidor é μ (i.e., o servidor é reparado em média ao fim $1/\mu$ unidades de tempo)
-

Então, a disponibilidade do servidor pode ser calculada pela cadeia de Markov:

estado 1: servidor disponível

estado 2: servidor indisponível (em reparação a uma falha)



A disponibilidade do servidor é a probabilidade do estado 1.

Análise da disponibilidade de um servidor

- Considerar um servidor como um único elemento pode ser um modelo demasiado simplista para analisar a sua disponibilidade
 - Um modelo mais realista é considerar um servidor como um sistema constituído por 2 elementos: Hardware + Software
-
- Assim, um servidor só está disponível se os 2 elementos estiverem disponíveis (mas as falhas não são independentes):
 - Falhas de hardware são geralmente associadas ao desgaste dos dispositivos físicos ao longo do tempo
 - Falhas de software acontecem devido a múltiplos problemas:
 - Bugs de software que se manifestam em situações raras
 - Corrupção de dados em múltiplas operações de escrita em memória
 - Erros numéricos em operações algorítmicas
 - Etc...
 - Tipicamente, falhas de hardware são mais raras que falhas de software, mas a resolução das falhas de hardware demora mais tempo que a resolução de falhas de software.

Disponibilidade de um servidor (ii)

Servidor modelado por 2 elementos: hardware + software

Considerando que:


- a taxa de falhas por unidade de tempo do servidor é λ_h (falhas de hardware) e λ_s (falhas de software)
- a taxa de reparações por unidade de tempo do servidor é μ_h (reparações de falhas de hardware) e μ_s (reparações de falhas de software)
- a reparação de uma falha de hardware inclui a reparação do software

Então, a disponibilidade do servidor pode ser calculada pela cadeia de Markov:

estado 1: servidor disponível

estado 2: servidor indisponível (em reparação a uma falha de hardware)

estado 3: servidor indisponível (em reparação a uma falha de software)



A disponibilidade do servidor é a probabilidade do estado 1.

Disponibilidade de um servidor (iii)

Servidor modelado por 2 elementos: hardware + software

Considerando que:


- a taxa de falhas por unidade de tempo do servidor é λ_h (falhas de hardware) e λ_s (falhas de software)
- a taxa de reparações por unidade de tempo do servidor é μ_h (reparações de falhas de hardware) e μ_s (reparações de falhas de software)
- a reparação de uma falha de hardware não inclui a reparação do software

Então, a disponibilidade do servidor pode ser calculada pela cadeia de Markov:

estado 1: servidor disponível

estado 2: servidor indisponível (em reparação a uma falha de hardware)



estado 3: servidor indisponível (em reparação a uma falha de software)



A disponibilidade do servidor é a probabilidade do estado 1.

Análise da disponibilidade de um servidor

- A análise da disponibilidade de um servidor pode ser ainda mais complexa.
- Por exemplo, os servidores em *Data Centers* são VMs (*Virtual Machines*) criados por um *Hypervisor* com recursos de CPU e de RAM dedicados a cada VM.
- A virtualização de servidores em VMs pode ser de dois tipos (<https://www.digihunch.com/2020/07/overview-of-virtualization>):
 - Tipo 1, em que o *Hypervisor* corre diretamente sobre o Hardware
 - Tipo 2, em que o *Hypervisor* corre sobre o sistema operativo (OS) do servidor



Disponibilidade de um servidor (iv)

Servidor modelado por 3 elementos: hardware + hypervisor + VM

Considerando que:


- a taxa de falhas do servidor é λ_h (falhas de hardware), λ_s (falhas de *hypervisor*) e λ_v (falhas de VM)
- a taxa de reparações do servidor é μ_h (reparações de falhas de hardware), μ_s (reparações de falhas de *hypervisor*) e μ_v (reparações de falhas de VM)
- a reparação de uma falha de hardware inclui as reparações do *hypervisor* + VM, e a reparação de uma falha de *hypervisor* inclui a reparação do VM

estado 1: servidor disponível

estado 2: servidor em reparação a uma falha de hardware

estado 3: servidor em reparação a uma falha de *Hypervisor*


estado 4: servidor em reparação a uma falha de VM



A disponibilidade do servidor é a probabilidade do estado 1.

Disponibilidade de múltiplos servidores


- Quando a disponibilidade de um servidor é menor do que o que se pretende para o(s) serviço(s) por ele suportado(s), é preciso considerar múltiplos servidores.



Disponibilidade de múltiplos servidores

Podemos considerar as disponibilidades dos diferentes servidores como estatisticamente independentes?

- Considere-se que temos n servidores e t técnicos de reparação (com $t < n$). A taxa de falhas de cada servidor é λ e a taxa de reparação de cada servidor por cada técnico é μ .
- A cadeia de Markov que modela o número de servidores indisponíveis é:




Assim:

- até t servidores indisponíveis, há um técnico para reparar cada servidor
- com mais de t servidores indisponíveis, há servidores que só começam a ser reparados quando outros acabarem de ser reparados (a disponibilidade não é independente entre servidores)

Disponibilidade de múltiplos servidores

Podemos considerar as disponibilidades dos diferentes servidores como estatisticamente independentes?

- Considere-se que temos $n = 15$ servidores e $t < 15$ técnicos de reparação. A taxa de falhas de cada servidor é $\lambda = 1/100$ por dia e a taxa de reparação de cada servidor por cada técnico é $\mu = 1$ por dia.



- Probabilidade P de i servidores disponíveis (i.e., $15 - i$ servidores indisponíveis) para diferentes valores de t
- A disponibilidade aumenta quando o t aumenta

i	t	P
15	1	85.1718%
14	1	12.7758%
15	2	86.1159%
14	2	12.9174%
15	3	86.1346%
14	3	12.9202%

Disponibilidade de múltiplos servidores

Podemos considerar as disponibilidades dos diferentes servidores como estatisticamente independentes?

- Por outro lado, se as disponibilidades dos servidores forem independentes, então o número de servidores disponíveis é uma variável binomial com:
 - probabilidade p igual à disponibilidade de cada servidor,
 - parâmetro n igual ao número de servidores.

Probabilidade de i servidores disponíveis é $f(i)$

$$f(i) = \binom{n}{i} p^i (1-p)^{n-i}, i = 0, 1, 2, \dots, n$$

Disponibilidade de múltiplos servidores

Podemos considerar as disponibilidades dos diferentes servidores como estatisticamente independentes?

- Considere-se que temos $n = 15$ servidores e $t < 15$ técnicos de reparação. A taxa de falhas de cada servidor é $\lambda = 1/100$ por dia e a taxa de reparação de cada servidor por cada técnico é $\mu = 1$ por dia.

$$p = \frac{MTBF}{MTBF + MTTR} = \frac{100}{100 + 1} = 0.990099$$

$$f(i) = \binom{n}{i} p^i (1-p)^{n-i}, i = 0, 1, 2, \dots, n$$

$$f(0) = (1 - p)^n = (1 - 0.990099)^{15} = 0.861349 = 86.1349\%$$

$$f(1) = np(1 - p)^{n-1} = 15 \times 0.990099 \times (1 - 0.990099)^{14} = 12.9202\%$$

- Comparação com os valores apresentados anteriormente:
 - para $t = 3$ técnicos, a disponibilidade dos servidores é aproximadamente independente.

i	t	P
15	1	85.1718%
14	1	12.7758%
15	2	86.1159%
14	2	12.9174%
15	3	86.1346%
14	3	12.9202%

Disponibilidade de serviços com servidores de backup

- Quando a disponibilidade de um servidor (a disponibilizar um serviço) é inferior a um valor desejado, é necessário ter mais servidores em paralelo (designados por servidores de backup) para se atingir a disponibilidade de serviço desejada:
 - os servidores de backup estão em standby e começam a ser usados quando o servidor atual de serviço falha,
 - assim, a disponibilidade do serviço é caracterizada por um conjunto de elementos em paralelo, pois o serviço só falha se todos os servidores (o de serviço e os de backup) falharem.
- Quando temos múltiplos servidores em que cada um disponibiliza um serviço diferente, podemos ter duas estratégias de backup:
 - servidores de backup dedicados: cada servidor de backup só é usado como backup a um único servidor de serviço
 - servidores de backup partilhados: os servidores de backup podem ser usados como backup a qualquer um dos servidores de serviço

Disponibilidade de serviços com servidores de backup

Considere-se 3 servidores de serviço (a proporcionar o serviço A, B e C, respetivamente) e b servidores de backup:



Considere-se que cada servidor tem uma disponibilidade de 0.995 e que cada serviço precisa de ter uma disponibilidade de pelo menos quatro noves (i.e., 99.99%).

- Com servidores de backup dedicados, temos de ter $b = 3$ servidores de backup, um por cada servidor de serviço:
 - Disponibilidade de cada serviço = $1 - (1 - 0.995) \times (1 - 0.995) = 0.99997500 = 99.997500\%$ que é maior que a disponibilidade desejada
- Com servidores de backup partilhados, podemos precisar de menos de 3 servidores de backup para atingir a mesma disponibilidade desejada (próximos slides).

Disponibilidade de serviços com servidores de backup

Considere-se 3 servidores de serviço (a proporcionar o serviço A, B e C, respetivamente) e b servidores de backup:



Considere-se que cada servidor tem uma disponibilidade de 0.995 e que cada serviço precisa de ter uma disponibilidade de pelo menos quatro noves (i.e., 99.99%).

-
- Considere-se $b = 1$ servidor de backup (assumindo que só pode funcionar como backup de um serviço de cada vez).
 - O servidor de backup está disponível para cada serviço:
 - a 100% quando falha até 1 servidor de serviço
 - a 50% quando falham 2 servidores de serviço
 - a 33.333% quando falham 3 servidores de serviço

Disponibilidade de serviços com servidores de backup



Cada servidor tem uma disponibilidade de 0.995 e que cada serviço precisa de uma disponibilidade de pelo menos 99.99%.

- Relembrar que em n servidores, i servidores falham com probabilidade $f(i) = \binom{n}{i} p^i (1-p)^{n-i}$ em que $p = 1 - 0.995$.
- Quando um serviço tem um servidor de backup, a sua disponibilidade é $1 - (1 - 0.995) \times (1 - 0.995) = 0.99997500$
- Assim, para $b = 1$ servidor de backup, a disponibilidade a de cada serviço é:

$$a = 0.99997500 \times \left(f(0) + f(1) + \frac{1}{2} \times f(2) + \frac{1}{3} \times f(3) \right) + 0.995 \times \left(\frac{1}{2} \times f(2) + \frac{2}{3} \times f(3) \right) = 0.9999748 = 99.997481\%$$

CONCLUSÃO: $b = 1$ servidor de backup é suficiente

Disponibilidade de serviços com servidores de backup

Considere-se 3 servidores de serviço (a proporcionar o serviço A, B e C, respetivamente) e b servidores de backup:



Considere-se que cada servidor tem uma disponibilidade de 0.995 e que cada serviço precisa de ter uma disponibilidade de pelo menos quatro noves (i.e., 99.99%).

- Com $b = 2$ servidores de backup (e assumindo que cada servidor de backup só pode funcionar como backup de um serviço de cada vez), os servidores de backup estão disponíveis para um serviço:
 - a 100% quando falham até 2 servidores de serviço
 - a 66.666% quando falham 3 servidores de serviço

Disponibilidade de serviços com servidores de backup



Cada servidor tem uma disponibilidade de 0.995 e que cada serviço precisa de uma disponibilidade de pelo menos 99.99%.

- Quando um serviço tem um servidor de backup, a sua disponibilidade é $1 - (1 - 0.995) \times (1 - 0.995) = 0.99997500$
- Assim, para $b = 2$ servidores de backup, a disponibilidade a de cada serviço é:

$$a = 0.99997500 \times \left(f(0) + f(1) + f(2) + \frac{2}{3} \times f(3) \right) + 0.995 \times \left(\frac{1}{3} \times f(3) \right) = 0.9999748 = 99.997499\%$$

CONCLUSÃO: com $b = 2$ servidores de backup, a disponibilidade é quase igual à solução com servidores de backup dedicados

Disponibilidade de serviços com servidores de backup

Sistemas baseados em servidores de backup dedicados

- São menos complexos de gerir:
 - cada servidor de backup tem de estar preparado apenas para o(s) serviço(s) suportado(s) pelo seu servidor de serviço(s)
 - a reposição do serviço para o servidor de serviço (quando este fica disponível) não tem requisitos temporais exigentes
- Impõem maiores custos, pois precisam de mais servidores de backup para atingir o valor desejado de disponibilidade

Sistemas baseados em servidores de backup partilhados


- São mais complexos de gerir:
 - cada servidor de backup tem de estar preparado para suportar os serviços de todos os servidores de serviço
 - a reposição do serviço para o seu servidor de serviço (quando este fica disponível) deverá ser rápida (para o servidor de backup ficar disponível como backup para outras falhas)
- Impõem menores custos, pois precisam de menos servidores de backup para atingir o valor desejado de disponibilidade

Disponibilidade de um serviço

- Muitos serviços são compostos por múltiplos elementos de serviço. Por exemplo, um serviço Web composto por:
 - um servidor Web,
 - uma base de dados (BD),
 - um servidor de autenticação,

está disponível se os 3 elementos de serviço estiverem disponíveis.


- Se todos os elementos do serviço correrem num único servidor, então a disponibilidade do serviço é a disponibilidade do servidor (i.e., todos os elementos falham quando o servidor falha).
- Se cada elemento do serviço correr num servidor diferente, então, o serviço é modelado pela série:



e a disponibilidade do serviço é a multiplicação das disponibilidades de cada um dos 3 elementos.

Disponibilidade e redundância

- Quando a disponibilidade de um sistema em série é inferior a um valor desejado A_d , é necessário adicionar redundância ao sistema para atingir a disponibilidade desejada.
- Considere-se um sistema em série com 3 elementos:



cujas disponibilidades são a_1 , a_2 e a_3 .

- Se $A (= a_1 \times a_2 \times a_3) < A_d$, é preciso adicionar redundância a um (ou mais) elementos do sistema.
- Assumindo que a redundância pode ser aplicada a quaisquer elementos do sistema, a pergunta é como adicionar a redundância mínima para atingir a disponibilidade desejada A_d .


Disponibilidade e redundância

Como adicionar a redundância mínima para atingir a disponibilidade desejada A_d ?

- De notar que:
 - num sistema em série, a disponibilidade do sistema é menor que a disponibilidade do elemento menos disponível
 - assim, tornar redundante o elemento menos disponível é a decisão que dá o maior ganho de disponibilidade
- Método:
 - 1) Identifica-se o elemento menos disponível e acrescenta-se um elemento em paralelo ao elemento identificado.
 - 2) Calcula-se a disponibilidade A do sistema resultante.
 - 3) Se $A < A_d$, retorna-se ao passo 1); caso contrário, o sistema atual é a solução final.


Disponibilidade e redundância – exemplo

- Considere-se um sistema em série com 3 elementos cuja disponibilidade desejada é $A_d = 0.999$ (três noves):



$$A = 0.95 \times 0.992 \times 0.9995 = 0.9419 \quad (A < A_d)$$


-
- 1ª iteração: o elemento 1 é o de menor disponibilidade



$$A = 0.9975 \times 0.992 \times 0.9995 = 0.989025 \quad (A < 0.999)$$


Disponibilidade e redundância – exemplo

- Resultado da 1ª iteração:



$$A = 0.9975 \times 0.992 \times 0.9995 = 0.989025$$


-
- 2ª iteração: o elemento 2 é o de menor disponibilidade



$$A = 0.9975 \times 0.999936 \times 0.9995 = 0.996937 \quad (A < 0.999)$$


Disponibilidade e redundância – exemplo

- Resultado da 2ª iteração:



$$A = 0.9975 \times 0.999936 \times 0.9995 = 0.996937$$


-
- 3ª iteração: o elemento 1/1 é o de menor disponibilidade



$$A = 0.999875 \times 0.999936 \times 0.9995 = \underline{\underline{0.9993}} \text{ (} A > 0.999 \text{)}$$

Disponibilidade de um serviço


- Voltando ao exemplo de um serviço Web composto por:
 - um servidor Web,
 - uma base de dados (BD),
 - um servidor de autenticação.



- Se cada elemento do serviço correr num servidor diferente e se as disponibilidades de cada elemento forem as do exemplo dos slides anteriores, então:
 - o Servidor Web deveria ter 2 servidores de backup dedicados,
 - o Servidor da BD deveria ter 1 servidor de backup dedicado.
- Os cenários práticos podem ser mais complicados do que este em diferentes aspetos (próximo slide)

Disponibilidade de um serviço

- Voltando ao exemplo de um serviço Web composto por:
 - um servidor Web,
 - uma base de dados (BD),
 - um servidor de autenticação.



- Os cenários práticos podem ser mais complicados:
 - alguns elementos podem correr no mesmo servidor (por exemplo, o Servidor Web e a BD a correr no mesmo servidor)
 - neste caso, as disponibilidades destes elementos não são independentes
 - alguns elementos podem ser também elementos de outros serviços (na UA, o PACO e o e-learning são dois serviços que recorrem ao mesmo Servidor de Autenticação),
 - a redundância destes elementos é dependente da disponibilidade desejada para cada serviço ao qual os elementos pertencem
 - o backup dos elementos com redundância pode ser baseado em servidores de backup partilhados.


Disponibilidade e backup de um serviço suportado por múltiplos servidores

- Em muitos casos, um serviço é suportado por mais que um servidor. Isto acontece devido a diferentes razões:
 - Quando a capacidade de um servidor (em termos de capacidade de processamento) não é suficiente para suportar o serviço com a qualidade desejada (por exemplo em termos de probabilidade de bloqueio ou de tempo médio de atendimento).
 - Quando o custo de múltiplos servidores de menor desempenho (quer em termos de capacidade quer em termos de disponibilidade) é menor que o custo de um único servidor de grande desempenho.
- Neste caso, é também possível ter ganhos de partilha de recursos de backup, i.e., o número b de servidores de backup não precisa de ser igual ao número de servidores n a suportar o serviço (próximos slides).

n Servidores de um Serviço



b Servidores de Backup



Disponibilidade e backup de um serviço suportado por múltiplos servidores

- Considere-se:
 - um serviço que, para cumprir com os requisitos de funcionamento precisa de correr em n servidores semelhantes,
 - cada servidor tem uma disponibilidade de a ,
 - pretende-se que o serviço tenha uma disponibilidade de A_d .
- Se o serviço tiver n servidores de serviço e não tiver servidores de backup, basta um servidor falhar que o serviço deixa de cumprir com os seus requisitos.
- Se o serviço tiver também b servidores de backup (semelhantes aos de serviço), então, a disponibilidade do serviço a_b é a probabilidade de estarem pelo menos n servidores disponíveis em $n + b$ servidores.
- Se a disponibilidade dos servidores for independente, então a_b é:

$$a_b = \sum_{i=n}^{n+b} \binom{n+b}{i} a^i (1-a)^{n+b-i}$$

- Assim, é preciso calcular o menor b tal que $a_b \geq A_d$

Disponibilidade e backup de um serviço suportado por múltiplos servidores

- Considere-se:
 - um serviço que, para cumprir com os requisitos de funcionamento precisa de correr em n servidores semelhantes,
 - cada servidor tem uma disponibilidade de a ,
 - pretende-se que o serviço tenha uma disponibilidade de A_d .

Cálculo do valor mínimo b (de servidores de backup) para uma disponibilidade de $A_d = 0.99999$ (cinco noves) e para diferentes valores de n e de a :

n	a	b
2 – 3	0.99	2
4 – 11	0.99	3
2 – 6	0.995	2
7 – 23	0.995	3
2 – 4	0.999	1
5 – 38	0.999	2

Para valores crescentes de a , o número b de servidores de backup necessários torna-se muito pequeno